

# Bayesian Analysis for Exponential Random Graph Models Using the Double Metropolis-Hastings Sampler

Gabriel Lima Novais

# Content

- Introdução
- Exponential Random Graphs Models (ERGM)
- Double Metropolis Hastings (DMH)
- Noisy Double Metropolis Hastings (NDMH)
- Aplicação
- Resultados
- Referências

# Introdução

- ▶ Markov Chain Monte Carlo (MCMC) quando utilizado no contexto de uma modelagem Bayesiana relaciona-se principalmente ao cálculo de Integrais.
- ▶ Em certas modelagens Bayesianas precisamos encontrar a constante de normalização ao mesmo tempo que tentamos amostrar da posteriori.
- ▶ Dessa forma, a solução proposta reside na aplicação do algoritmo de Metropolis Hastings com a adição de uma variável auxiliar.

# Introdução

Considere o seguinte esquema a seguir:

- ▶  $h(x|\theta)$  um modelo de probabilidade não normalizado.
- ▶  $x \in X$  e  $\theta \in \Theta$ .
- ▶  $Z(\theta) = \int_X h(x|\theta)dx$  uma função de normalização.
- ▶  $p(\theta)$  a priori da densidade de  $\theta$ .

Então a posteriori  $\pi(\theta|x)$  será:

$$\pi(\theta|x) \propto p(\theta) \frac{h(x|\theta)}{Z(\theta)}$$

# Introdução

- ▶ O problema na construção do MCMC reside no fato de que  $Z(\theta)$  não consegue ser analiticamente calculada.
- ▶ A probabilidade de aceitação calculada em cada passo do MH implica em calcular  $Z(\theta)$  tanto no valor atual como no valor proposto de  $\theta$ .
- ▶ Uma forma de lidar com este problema pode ser com a inclusão de uma variável auxiliar. Exemplo: DMH.

# Introdução

- ▶ Uma variável auxiliar "bem comportada", quando no cálculo da razão de aceitação, termina por cancelar a função de normalização e assim o MH pode ser aplicado.
- ▶ A aplicação do método de DMH será realizada em cima da modelagem de redes com uma função de distribuição.
- ▶ Objetivo: recuperar certos parâmetros desta rede e realizar uma comparação com outro método similar.

# Exponential Random Graphs Models (ERGM)

- ▶ A família de grafos exponenciais aleatórios (ERGM) são muito utilizados para modelar redes sociais.
- ▶ Dizemos que a rede pertence a uma ERGM se a probabilidade de um nó se a ligar a outro é determinada por uma função de densidade exponencial, que geralmente é descrita segundo a seguinte equação:

$$f(x|\theta) = \frac{\exp(\sum_i \theta_i S_i(x))}{k(\theta)}$$

# Exponential Random Graphs Models (ERGM)


- ▶ A função de densidade acima é função do input  $x$ , que denota a matrix de adjacência da rede em questão. Logo, a probabilidade seria algo como o elemento da matriz ser 0 ou 1.
- ▶ O objetivo será estimar cada parâmetro  $\theta_i$  associado a cada estatística suficiente  $S_i(x)$  do numerador. O denominador  $k(\theta)$  é a constante de normalização intratável.
- ▶ Veja que a aplicação do DMH surge como uma solução viável para estimar  $\theta_i$  com  $k(\theta)$  pela função de densidade.



# Double Metropolis Hastings (DMH)

- ▶ Liang (2009) propôs o algoritmo como uma solução para amostrar de funções cujas constantes de normalização são intratáveis.
- ▶ O que o DMH faz é justamente aumentar o espaço estado da cadeia de Markov utilizando uma variável auxiliar no Metropolis Hastings tradicional.
- ▶ Pelo fato dessa variável auxiliar passar por outro Metropolis Hastings dentro do principal, o nome concebido foi o de "Double Metropolis Hastings".

# Double Metropolis Hastings (DMH)



# Double Metropolis Hastings (DMH)

## The DMH Sampler

- (a) Simulate a new sample  $\theta'$  from  $\pi(\theta)$  using the MH algorithm starting with  $\theta_t$ .
- (b) Generate an auxiliary variable  $y$  from  $f(y|\theta')$  through  $m$  MH updates starting with  $x$ . The probability of transition from  $x$  to  $y$  is

$$P_{\theta'}^{(m)}(y|x) = K_{\theta'}(x \rightarrow x_1) \cdots K_{\theta'}(x_{m-1} \rightarrow y) \quad (4)$$

Accept  $y$  with probability  $\min\{1, r(\theta_t, \theta', y|x)\}$ , where

$$r(\theta_t, \theta', y|x) = \frac{f(y|\theta_t)P_{\theta'}^{(m)}(x|y)}{f(x|\theta_t)P_{\theta'}^{(m)}(y|x)} = \frac{f(y|\theta_t)f(x|\theta')}{f(x|\theta_t)f(y|\theta')} = \frac{\psi(y, \theta_t)\psi(x, \theta')}{\psi(x, \theta_t)\psi(y, \theta')}. \quad (5)$$

- (c) Set  $\theta_{t+1} = \theta'$  if the auxiliary variable is accepted in step (b), and set  $\theta_{t+1} = \theta_t$  otherwise.

# Noisy Double Metropolis Hastings (NDMH)

- ▶ Consiste em certas adaptações do DMH. Em que constam duas modificações principais:
  - ▶ (1) Ao invés de utilizarmos uma variável auxiliar apenas, acrescentam-se  $N$  variáveis de forma que o Inner-Sample seja feito para todas estas  $N$  variáveis.
  - ▶ (2) A razão de aceitação é então modificada e assim teremos que a probabilidade de aceitação do novo  $\theta$  no segundo MH dependerá dessas variáveis acrescentadas.

# Noisy Double Metropolis Hastings (NDMH)

A nova razão de aceitação pode ser então descrita por:

$$r(\theta_t, \theta', y|x) = \frac{\psi(x, \theta')}{\psi(x, \theta_t)} \frac{1}{N} \sum_{i=1}^N \frac{\psi(y_i, \theta_t)}{\psi(y_i, \theta')}$$

E então teremos que:

$$\alpha = \min(1, r(\theta_t, \theta', y|x))$$

# Aplicação

- ▶ A base de dados escolhida para fazer a aplicação do DMH e NDMH é a Florentine, uma rede que é amplamente utilizada como "toy model".
- ▶ A rede possui 10 nós, formando uma matriz de adjacência de  $10 \times 10$  de dimensão. Não existem nós que se ligam a si mesmos e as arestas não são direcionadas.
- ▶ Além desta base procurou-se utilizar uma outra simulada composta de 50 nós, e veriicou-se pelo MCMCMLE o valor dos seus parâmetros. Neste caso, conforme veremos mais a frente, a simulação obteve um tempo de execução alto.

# Aplicação

- ▶ O procedimento para elaboração do DMH foi a seguinte:
  - 1 Tomar  $\theta_0$  de uma normal multivariada com média zero e variância alta.
  - 2 Considerar a evolução dos  $\theta_t$  como um random walk cujo step size modifica a variância da normal e a média é atualizada pelo  $\theta_{t-1}$
  - 3 Atualizar os elementos da matriz de adjacência por uma probabilidade específica, por meio de uma rodada única de Gibbs Sampler.
  - 4 Com a matriz atualizada calcular a razão de aceitação e verificar se o  $\theta_t$  é aceito e assim finalizar o MH principal.

# Aplicação

- ▶ Custos computacionais: além de precisar de muitas iterações (por ser uma técnica de Monte Carlos), o algoritmo também precisa varrer uma matriz cuja dimensão pode ser grande.
- ▶ Tanto para o DMH quanto para o NDMH verifica-se a ordem do algoritmo de  $n^2$ . Entretanto como a aplicação é voltada para redes, verifica-se que no máximo a complexidade se torna  $n^4$ .
- ▶ Grande parte dos custos relaciona-se não somente ao MH, mas também ao cálculo das estatísticas suficientes em especial a  $EP(x)$



# Resultados

- ▶ Os dados foram obtidos e gerados pelo R. A implementação do DMH foi inicialmente feita no Python, mas pelo fato de não executar em tempo viável, optou-se por implementar em Julia, que nos forneceu um tempo de execução aproximadamente 5 vezes menor.
- ▶ Para a rede "Florentine" os parâmetros procurados pela estimação do modelo 2 eram de  $\theta_1 = -1.66$  e  $\theta_2 = 0.15$ . Já para o de 50 nós simulado o resultado deveria fornecer algo próximo de  $\theta_1 = -3.19$  e  $\theta_2 = 0.39$ .

# Resultados

- ▶ Foram utilizados os parâmetros a seguir para ambas as redes:
  - ▶  $\dim = 2$
  - ▶  $\tau = 0.25$
  - ▶  $n_{iter} = 10500/1000$
  - ▶  $var_{init} = 200$
  - ▶ step-size = 0.2
- ▶ obs: para o NDMH foram utilizadas 3 variáveis auxiliares.


# Resultados

Quadro comparativo entre os métodos:

Método	Rede	Tempo	Iteração	$\theta_1$	$\theta_2$
NDMH	10	26 min e 27 s	10500	-0.796426	0.405188
DMH	10	6 min e 51 s	10500	-1.74165	0.882828
DMH	50	2h 35 min 28 s	1000	-3.19041	-0.441341



# Resultados

DMH - rede: 10 nós




# Resultados

DMH - rede: 10 nós





# Resultados

NDMH - rede: 10 nós




# Resultados

NDMH - rede: 10 nós



# Resultados



DMH - rede: 50 nós





# Resultados

DMH - rede: 50 nós



# Referências

- ▶ PARK, Jaewoo; HARAN, Murali. Bayesian inference in the presence of intractable normalizing functions.
- ▶ JIN, Ick Hoon; LIANG, Faming. Bayesian analysis for exponential random graph model using double Metropolis-Hastings sampler.
- ▶ LIANG, Faming; JIN, Ick-Hoon. A Monte Carlo Metropolis-Hastings algorithm for sampling from distributions with intractable normalizing constants.
- ▶ STIVALA, Alex; ROBINS, Garry; LOMI, Alessandro. Exponential random graph model parameter estimation for very large directed networks..