

Estatística Computacional - Lista 3

Gabriel Lima Novais

November 11, 2019

Exercise 1 (Gibbs Sampler)

(Q1) Sabemos que o Kernel pode ser descrito como função de $\pi_{X|Y}$ e $\pi_{Y|X}$ tal como se segue abaixo:

$$K_{X,Y}^S((x, y), (x', y')) = \pi_{X|Y}(x'|y')\pi_{Y|X}(y'|x)$$

e também temos que:

$$K_{X,Y}^S((x', y'), (x, y)) = \pi_{X|Y}(x|y)\pi_{Y|X}(y|x')$$

Para que o Kernel seja reversível é preciso que:

$$\pi_{X,Y}(x, y)K_{X,Y}^S((x, y), (x', y')) = \pi_{X,Y}(x', y')K_{X,Y}^S((x', y'), (x, y))$$

Mas realizando as contas veja que:

$$\begin{aligned}\pi_{X,Y}(x, y)K_{X,Y}^S((x, y), (x', y')) &= \pi_{X,Y}(x, y)\pi_{X|Y}(x'|y')\pi_{Y|X}(y'|x) = \\ &= \pi_{X,Y}(x, y)\pi_{X,Y}(x', y')\pi_Y(y')\pi_{Y|X}(y'|x)\end{aligned}$$

e que:

$$\begin{aligned}\pi_{X,Y}(x', y')K_{X,Y}^S((x', y'), (x, y)) &= \pi_{X,Y}(x', y')\pi_{X|Y}(x|y)\pi_{Y|X}(y|x') = \\ &= \pi_{X,Y}(x', y')\pi_{X,Y}(x, y)\pi_Y(y)\pi_{Y|X}(y|x')\end{aligned}$$

Portanto, fica perceptível que ambas são diferentes, pois $\pi_Y(y')\pi_{Y|X}(y'|x) \neq \pi_Y(y)\pi_{Y|X}(y|x')$. Logo é não reversível.

(Q2) Pelo item anterior temos que:

$$K_{X,Y}^S((x, y), (x', y')) = \pi_{X|Y}(x'|y')\pi_{Y|X}(y'|x)$$

Logo:

$$\int K_{X,Y}^S((x, y), (x', y'))dy' = \int \pi_{X|Y}(x'|y')\pi_{Y|X}(y'|x)dy'$$

Considerando que o Kernel $K_X^S(x, x')$ seja apenas em função de x então podemos tomar que a cadeia de Markov $(X^{(t)})$ será independente de Y e assim:

$$K_X^S(x, x') = \int K_{X,Y}^S((x, y), (x', y')) dy' = \int \pi_{X|Y}(x'|y') \pi_{Y|X}(y'|x) dy'$$

Mas utilizando Bayes e rearranjando a equação acima teremos que:

$$K_X^S(x, x') = \int \pi_{X|Y}(x'|y') \pi_{Y|X}(y'|x) dy' = \int \frac{\pi_{X,Y}(x', y')}{\pi_Y(y')} \frac{\pi_{X,Y}(x, y')}{\pi_X(x)} dy'$$

Ou seja:

$$\pi_X(x) K_X^S(x, x') = \int \frac{\pi_{X,Y}(x', y')}{\pi_Y(y')} \pi_{X,Y}(x, y') dy'$$

Por outro lado temos também que de maneira análoga:

$$\pi_X(x') K_X^S(x', x) = \int \frac{\pi_{X,Y}(x, y)}{\pi_Y(y)} \pi_{X,Y}(x', y) dy$$

Fazendo a troca de variável y para y' temos que as duas equações elaboradas são iguais, ou seja:

$$\pi_X(x) K_X^S(x, x') = \pi_X(x') K_X^S(x', x)$$

O que demonstra a reversibilidade do Kernel em questão.

(Q3) Tomando o Scan Gibbs Sampler descrito no enunciado da questão, ou seja, com $P(J = 1) = P(J = 2) = 1/2$ teremos que:

$$K_{X,Y}^R((x, y), (x', y')) = \frac{1}{2} \pi_{X|Y}(x'|y) \delta(y') + \frac{1}{2} \pi_{Y|X}(y'|x) \delta(x')$$

Por outro lado temos que a forma reversa do Kernel seria tal que:

$$K_{X,Y}^R((x', y'), (x, y)) = \frac{1}{2} \pi_{X|Y}(x|y') \delta(y) + \frac{1}{2} \pi_{Y|X}(y|x') \delta(x)$$

Utilizando Bayes nessa última equação obtemos:

$$K_{X,Y}^R((x', y'), (x, y)) = \frac{1}{2} \frac{\pi_{X,Y}(x, y')}{\pi_Y(y')} \delta(y) + \frac{1}{2} \frac{\pi_{X,Y}(x', y)}{\pi_X(x')} \delta(x)$$

Mas:

$$\pi_{X,Y}(x', y') K_{X,Y}^R((x', y'), (x, y)) = \frac{1}{2} \pi_{X|Y}(x'|y') \pi_{X,Y}(x, y') \delta(y) + \frac{1}{2} \pi_{Y|X}(y'|x') \pi_{X,Y}(x', y) \delta(x)$$

Dividindo por $\pi_{X,Y}(x, y)$ teremos que:

$$\begin{aligned} \frac{\pi_{X,Y}(x', y')}{\pi_{X,Y}(x, y)} K_{X,Y}^R((x', y'), (x, y)) &= \frac{1}{2} \frac{1}{\pi_{X|Y}(x|y) \pi_Y(y)} \pi_{X|Y}(x'|y') \pi_{X,Y}(x, y') \delta(y) + \\ &+ \frac{1}{2} \frac{1}{\pi_{Y|X}(y|x) \pi_X(x)} \pi_{Y|X}(y'|x') \pi_{X,Y}(x', y) \delta(x) \end{aligned}$$

Por Kronecker, o valor só será relevante quando os mesmos forem o que se encontram entre parênteses, e assim:

$$\frac{\pi_{X,Y}(x', y')}{\pi_{X,Y}(x, y)} K_{X,Y}^R((x', y'), (x, y)) = \frac{1}{2} \pi_{X|Y}(x'|y) \delta(y') + \frac{1}{2} \pi_{Y|X}(y'|x) \delta(x') = K_{X,Y}^R((x, y), (x', y'))$$

Ou seja, o Kernel em questão é de fato reversível.

Exercise 2 (Metropolis-within-Gibbs)

(Q1) Queremos analisar o que ocorre quando o caso de amostrar da outra densidade condicional é possível e desta forma o MWG se torna simplesmente o Random Scan Gibbs Sampler. Para isso vamos analisar a probabilidade α dada no algoritmo do Metropolis-Hastings:

$$\alpha(X_1|X_1^{t-1}, X_2^{t-1}) = \min \left(1, \frac{\pi(X_1, X_2^{t-1}) q(X_1^{t-1}|X_1, X_2^{t-1})}{\pi(X_1^{t-1}, X_2^{t-1}) q(X_1|X_1^{t-1}, X_2^{t-1})} \right)$$

Mas fazendo $q(x'_1|x_1, x_2) = \pi_{X_1|X_2}(x'_1|x_2)$ teremos que:

$$\alpha(X_1|X_1^{t-1}, X_2^{t-1}) = \min \left(1, \frac{\pi(X_1, X_2^{t-1}) \pi_{X_1|X_2}(X_1^{t-1}|X_2^{t-1})}{\pi(X_1^{t-1}, X_2^{t-1}) \pi_{X_1|X_2}(X_1|X_2^{t-1})} \right)$$

Abrindo o primeiro termo do numerador e do denominador com a regra de Bayes chegamos em:

$$\alpha(X_1|X_1^{t-1}, X_2^{t-1}) = \min \left(1, \frac{\pi_{X_2}(X_2^{t-1}) \pi_{X_1|X_2}(X_1|X_2^{t-1}) \pi_{X_1|X_2}(X_1^{t-1}|X_2^{t-1})}{\pi_{X_2}(X_2^{t-1}) \pi_{X_1|X_2}(X_1^{t-1}|X_2^{t-1}) \pi_{X_1|X_2}(X_1|X_2^{t-1})} \right)$$

Cancelando os termos iguais na razão dentro do mínimo podemos encontrar que:

$$\alpha(X_1|X_1^{t-1}, X_2^{t-1}) = \min(1, 1) = 1$$

E assim concluímos o que desejávamos.

(Q2) Sabemos que o Kernel de transição (conforme é apresentado nos slides) é dado por:

$$K((x_1, x_2), (x'_1, x'_2)) = (\alpha(x'_1|x_1, x_2) q(x'_1|x_1, x_2) + (1 - \alpha(x_1, x_2)) \delta_{x_1}(x'_1)) \pi_{X_2|X_1}(x'_2|x'_1)$$

Onde sabemos que:

$$a(x_1, x_2) = \int \alpha(u|x_1, x_2) q(u|x_1, x_2) du$$

Para verificar a invariância de π precisamos integrar o Kernel, e para isso será realizada a integração duas vezes, pois ele é definido com o par (x_1, x_2) . Assim temos que:

$$\int \int \pi(x_1, x_2) K((x_1, x_2), (x'_1, x'_2)) dx_1 dx_2$$

Substituindo nessa integral dupla os valores anteriores temos que:

$$\int \int \pi(x_1, x_2) K((x_1, x_2), (x'_1, x'_2)) dx_1 dx_2 =$$

$$\begin{aligned}
&= \int \int \pi(x_1, x_2)(\alpha(x'_1|x_1, x_2)q(x'_1|x_1, x_2) + (1 - a(x_1, x_2))\delta_{x_1}(x'_1))\pi_{X_2|X_1}(x'_2|x'_1)dx_1dx_2 = \\
&= \int \int \pi_{X_2}(x_2)\pi_{X_1|X_2}(x_1|x_2)(\alpha(x'_1|x_1, x_2)q(x'_1|x_1, x_2) + (1 - a(x_1, x_2))\delta_{x_1}(x'_1))\pi_{X_2|X_1}(x'_2|x'_1)dx_1dx_2 =
\end{aligned}$$

Separando em cada componente e deslocando a integral:

$$= \int \pi_{X_2}(x_2) \int \pi_{X_1|X_2}(x_1|x_2)(\alpha(x'_1|x_1, x_2)q(x'_1|x_1, x_2) + (1 - a(x_1, x_2))\delta_{x_1}(x'_1))dx_1 \pi_{X_2|X_1}(x'_2|x'_1)dx_2 =$$

Porém veja que:

$$\int \pi_{X_1|X_2}(x_1|x_2)(\alpha(x'_1|x_1, x_2)q(x'_1|x_1, x_2) + (1 - a(x_1, x_2))\delta_{x_1}(x'_1))dx_1 = \pi_{X_1|X_2}(x'_1|x_2)$$

Então utilizando este fato e Bayes encontramos que:

$$\begin{aligned}
&\int \int \pi(x_1, x_2)K((x_1, x_2), (x'_1, x'_2))dx_1dx_2 = \int \pi_{X_2}(x_2)\pi_{X_1|X_2}(x'_1|x_2)\pi_{X_2|X_1}(x'_2|x'_1)dx_2 \implies \\
&\implies \int \int \pi(x_1, x_2)K((x_1, x_2), (x'_1, x'_2))dx_1dx_2 = \int \pi(x'_1, x_2)\pi_{X_2|X_1}(x'_2|x'_1)dx_2 = \pi_{X_1}(x'_1)\pi_{X_2|X_1}(x'_2|x'_1) \implies \\
&\implies \int \int \pi(x_1, x_2)K((x_1, x_2), (x'_1, x'_2))dx_1dx_2 = \pi(x'_1, x'_2)
\end{aligned}$$

Portanto chegamos no fato de que o Kernel deixa a distribuição π invariante.

Exercise 3 (Metropolis-Hastings and Gibbs Sampler)

(Q1) Queremos mostrar que:

$$\pi(x)T(x, y) = \pi(y)T(y, x)$$

Veja que:

$$\begin{aligned}
T(x, y) &= \alpha(x, y)q(x, y) + (1 - \sum \alpha(x, z)q(x, z))\delta(y) = \frac{\gamma(x, y)}{\pi(x)q(x, y)}q(x, y) + (1 - \sum \frac{\gamma(x, z)}{\pi(x)q(x, z)}q(x, z))\delta(y) \implies \\
&\implies T(x, y) = \frac{\gamma(x, y)}{\pi(x)} + (1 - \sum \frac{\gamma(x, z)}{\pi(x)})\delta(y)
\end{aligned}$$

Agora veja que:

$$T(y, x) = \frac{\gamma(y, x)}{\pi(y)} + (1 - \sum \frac{\gamma(y, z)}{\pi(y)})\delta(x)$$

Retirando o denominador de ambos os T's obtemos as duas equações que seguem:

$$(1) \pi(x)T(x, y) = \gamma(x, y) + (\pi(x) - \sum \gamma(x, z))\delta(y)$$

$$(2) \quad \pi(y)T(y, x) = \gamma(y, x) + (\pi(y) - \sum \gamma(y, z))\delta(x)$$

Como sabemos que $\gamma(x, y) = \gamma(y, x)$ e que δ é um símbolo de Kronecker o resultado pedido foi encontrado, ou seja, (1)=(2).

(Q2) Para o algoritmo de Metropolis-Hastings, temos que a probabilidade $\alpha(x, y)$ é dada por:

$$\alpha(x, y) = \min(1, \frac{\pi(y)q(y, x)}{\pi(x)q(x, y)})$$

Multiplicando dos dois lados por $\pi(x)q(x, y)$ encontramos que:

$$\begin{aligned} \pi(x)q(x, y)\alpha(x, y) &= \pi(x)q(x, y)\min(1, \frac{\pi(y)q(y, x)}{\pi(x)q(x, y)}) \implies \\ \implies \pi(x)q(x, y)\alpha(x, y) &= \min(\pi(x)q(x, y), \pi(y)q(y, x)) \implies \\ \gamma(x, y) &= \min(\pi(x)q(x, y), \pi(y)q(y, x)) \end{aligned}$$

Agora fazendo o processo inverso para o algoritmo de Baker, isto é, dividindo ambos os lados por $\pi(x)q(x, y)$, encontramos o seguinte:

$$\begin{aligned} \gamma(x, y) &= \frac{\pi(x)q(x, y)\pi(y)q(y, x)}{\pi(x)q(x, y) + \pi(y)q(y, x)} \implies \\ \implies \frac{\gamma(x, y)}{\pi(x)q(x, y)} &= \frac{1}{\pi(x)q(x, y)} \frac{\pi(x)q(x, y)\pi(y)q(y, x)}{\pi(x)q(x, y) + \pi(y)q(y, x)} \implies \\ \implies \alpha(x, y) &= \frac{\pi(y)q(y, x)}{\pi(x)q(x, y) + \pi(y)q(y, x)} \end{aligned}$$

E esta é a probabilidade de aceitação pedida.

(Q3) Nessa questão queremos verificar qual dos dois Kernels de Transição é o menor. Para isso analisemos o caso em que $x \neq y$ (e lembrando das respostas obtidas no item anterior) e assim temos então:

$$(MH) \quad TMH = \alpha(x, y)q(x, y) = \frac{\gamma(x, y)}{\pi(x)} = \frac{\min(\pi(x)q(x, y), \pi(y)q(y, x))}{\pi(x)}$$

$$(B) \quad TB = \alpha(x, y)q(x, y) = \frac{\gamma(x, y)}{\pi(x)} = \frac{1}{\pi(x)} \frac{\pi(x)q(x, y)\pi(y)q(y, x)}{\pi(x)q(x, y) + \pi(y)q(y, x)}$$

Agora precisamos analisar quem é o maior deles. Suponha sem perda de generalidade (para o outro caso o problema é análogo) que $\pi(x)q(x, y) \leq \pi(y)q(y, x)$. Então teremos que :

$$TMH = q(x, y)$$

$$TB = q(x, y) \frac{\pi(y)q(y, x)}{\pi(x)q(x, y) + \pi(y)q(y, x)}$$

Logo teremos que:

$$TB = TMH \times r$$

onde $r = \frac{\pi(y)q(y,x)}{\pi(x)q(x,y)+\pi(y)q(y,x)}$.

Veja que $r \leq 1$ e desta forma temos que $TB = r \times TMH \leq 1 \times TMH$. Portanto temos que $TB \leq TMH$. Por outro lado sabemos do Teorema citado no enunciado da questão que o T que for maior possui uma variância assintótica menor. Logo o TMH possui essa variância assintótica menor

(Q4) Vamos utilizar a definição dada no enunciado para o cálculo do Kernel de Transição. Verificar que os Kernels de Transição são π reversíveis segue a mesma lógica apresentada em itens anteriores.

Veja que para valores de $y_k \neq x_k$, a equação de $T(x, y)$ vira $T(x, y) = \alpha(x, y)q(x, y)$. Logo para o Random Scan Gibbs Sampler o valor do Kernel de Transição pode ser descrito como:

$$TRSG(x, y) = \frac{\pi_{X_K|X_{-K}}(y_K|x_{-K})\delta_{x_{-K}}(y_{-K})}{d}$$

Vale ressaltar que o valor d que está dividindo a equação acima provém de uma distribuição uniforme, que equivale em termos de notação ao valor de $\pi(x)$ dos itens anteriores. Agora seguindo o mesmo procedimento para o Modified Random Scan Gibbs Sampler, podemos escrever:

$$\begin{aligned} TMRSG(x, y) &= \frac{q(y_K|x_{-K})\min\left(1, \frac{1-\pi_{X_K|X_{-K}}(x_K|x_{-K})}{1-\pi_{X_K|X_{-K}}(y_K|x_{-K})}\right)\delta_{x_{-K}}(y_{-K})}{d} \Rightarrow \\ \Rightarrow TMRSG(x, y) &= \frac{\frac{\pi_{X_K|X_{-K}}(y_K|x_{-K})}{1-\pi_{X_K|X_{-K}}(x_K|x_{-K})}\min\left(1, \frac{1-\pi_{X_K|X_{-K}}(x_K|x_{-K})}{1-\pi_{X_K|X_{-K}}(y_K|x_{-K})}\right)\delta_{x_{-K}}(y_{-K})}{d} \Rightarrow \\ \Rightarrow TMRSG(x, y) &= \pi_{X_K|X_{-K}}(y_K|x_{-K})\frac{\min\left(\frac{1}{1-\pi_{X_K|X_{-K}}(y_K|x_{-K})}, \frac{1}{1-\pi_{X_K|X_{-K}}(x_K|x_{-K})}\right)\delta_{x_{-K}}(y_{-K})}{d} \end{aligned}$$

Agora tal como foi feito no item anterior, temos como objetivo calcular quem será o maior deles, pois de acordo com o teorema do enunciado do item 3, este será o que possui menor variância assintótica e portanto para o nosso caso isto será o melhor. Vamos então a comparação:

$$TMRSG(x, y) \geq TRSG(x, y)$$

Logo, o MRSB é o que possui menor variância assintótica.

Exercise 4 (Metropolis-Hastings)

(Q1) A "proposal" é simplesmente uma integral em θ tal que:

$$q(x'|x) = \int g(x'|\theta)f(\theta|x)d\theta$$

Isso se deve ao fato de que $V \sim f(\cdot)$ e que $X \sim g(\cdot)$. O maior problema da função $f(\cdot)$ é que não sabemos avaliar a mesma de forma pontual e isso gera uma dificuldade em se calcular a probabilidade α de aceitação do algoritmo de Metropolis-Hastings.

- (Q2) Considerando a forma randomizada do algoritmo de Metropolis-Hastings descrita no enunciado, podemos verificar que a razão presente na probabilidade de aceitação seria justamente:

$$r = \frac{\pi(x')g(x|\theta')}{\pi(x)g(x'|\theta)}$$

Agora façamos algumas manipulações algébricas para encontrar a razão r no formato que seria no caso de um "target" de $\bar{\pi}(x, \theta)$:

$$r = \frac{\pi(x')g(x|\theta')}{\pi(x)g(x'|\theta)} \implies r = \frac{\pi(x')g(x|\theta')}{\pi(x)g(x'|\theta)} \frac{f(\theta|x)f(\theta'|x')}{f(\theta|x)f(\theta'|x')} \implies$$

Agora juntando os termos convenientemente e depois lembrando que $\bar{\pi}(x) = \pi(x)$ podemos encontrar:

$$\begin{aligned} r &= \frac{\pi(x')g(x|\theta')}{\pi(x)g(x'|\theta)} \frac{f(\theta|x)f(\theta'|x')}{f(\theta|x)f(\theta'|x')} \implies r = \frac{\pi(x')f(\theta'|x')g(x|\theta')f(\theta|x)}{\pi(x)f(\theta|x)g(x'|\theta)f(\theta'|x')} \implies \\ &\implies r = \frac{\pi(x', \theta')g(x|\theta')f(\theta|x)}{\pi(x, \theta)g(x'|\theta)f(\theta'|x')} = \frac{\bar{\pi}(x', \theta')g(x|\theta')f(\theta|x)}{\bar{\pi}(x, \theta)g(x'|\theta)f(\theta'|x')} \end{aligned}$$

Ou seja, caso tomemos uma proposta tal que $q((x', \theta')|(x, \theta)) = g(x'|\theta)f(\theta'|x')$, então encontramos que o $\bar{r} = r$. Logo podemos concluir que o Kernel de transição possui uma distribuição invariante $\bar{\pi}$.

- (Q3) Utilizando a decomposição conhecida do mínimo dada por $\min(U, V) = \frac{U+V}{2} - \frac{|V-U|}{2}$ temos que:

$$\begin{aligned} E(\min(U, V)) &= E\left(\frac{U+V}{2} - \frac{|V-U|}{2}\right) = E\left(\frac{V-U+2U}{2} - \frac{|V-U|}{2}\right) \\ &= E\left(U + \frac{V-U}{2} - \frac{|V-U|}{2}\right) = E(U) + E\left(\frac{V-U}{2} - \frac{|V-U|}{2}\right) = \\ &= E(U) + \frac{E(V-U)}{2} - \frac{E(|V-U|)}{2} \end{aligned}$$

ou de forma análoga poderíamos ter que:

$$E(\min(U, V)) = E(V) + \frac{E(U-V)}{2} - \frac{E(|U-V|)}{2}$$

Se assumirmos que $E(V) \geq E(U)$ então $E(|V-U|) \geq E(V-U)$ e então sabemos que $E(\min(U, V)) \leq E(U)$ e desta maneira conseguimos achar que $\min(E(U), E(V)) = E(U)$ e assim provamos o que foi pedido. Por outro lado caso se tomarmos o caso contrário, $E(V) \leq E(U)$, podemos verificar que $E(|V-U|) \leq E(V-U)$ e assim $\min(E(U), E(V)) = E(V)$, o que também prova o que foi pedido.

- (Q4) Dúvida!

Exercise 5 (Thinning of a Markov chain)

- (Q1) Apesar de podermos considerar o valor esperado um operador Linear e então demonstrar com os conhecimentos de álgebra linear, vamos utilizar a dica. Veja que:

$$(Y - \alpha Z)^2 \geq 0 \implies E((Y - \alpha Z)^2) \geq 0 \implies$$

$$\begin{aligned} &\implies E(Y^2 - 2\alpha YZ + \alpha^2 Z^2) \geq 0 \implies \\ &\implies E(Y^2) - 2\alpha E(YZ) + \alpha^2 E(Z^2) \geq 0 \end{aligned}$$

Veja que a equação acima se trata de um polinômio do segundo grau em termos de α . Portanto para que o valor seja positivo tal como está descrito acima precisamos que o valor do Δ seja menor do que zero para todo número do domínio. Assim, calculemos este valor:

$$\begin{aligned} \Delta \leq 0 &\implies (2E(YZ))^2 - 4(E(Z^2))(E(Y^2)) \leq 0 \implies \\ &\implies (E(YZ))^2 \leq E(Z^2)E(Y^2) \end{aligned}$$

Fornecendo exatamente a desigualdade que queríamos encontrar.

(Q2) Utilizando a fórmula da covariância temos que:

$$Cov(YZ) = E(YZ) - E(Y)E(Z)$$

Mas considerando os valores de $E(Y) = E(Z)$ então podemos fazer (associado ao Cauchy-Schwartz) a seguinte manipulação:

$$\begin{aligned} Cov(YZ) &= E(YZ) - E(Y)E(Z) \leq \sqrt{E(Y^2)E(Z^2)} - E(Y)E(Z) = \\ &= \sqrt{E(Y^2)E(Y^2)} - E(Y)E(Y) = E(Y^2) - E^2(Y) = Var(Y) \end{aligned}$$

E assim obtemos o resultado pedido.

(Q3) Dúvida!

Simulation question (Probit model — Gibbs and M-H)

(Q1) A minha escolha dos parâmetros foram:

- $\beta^T = [3, -2]$
- $n = 50$
- $qtd(Y_i = 0) = 20$ e $qtd(Y_i = 1) = 30$

Para conseguir estruturar o raciocínio e o próprio código utilizou-se a "seed" = 50.

(Q2) A função de verossimilhança pode ser dada por:


$$P(Y_1 = k_1, \dots, Y_n = k_n \mid \beta) = \prod_{i=1}^n \Phi(X_i^T \beta)^{k_i} (1 - \Phi(X_i^T \beta))^{1-k_i}$$

Para a realização do cálculo da distribuição da prior utilizou-se a seguinte matriz de covariância:


$$\Sigma = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

Então tendo em posse a função que calculava a prior de β e uma função que calculava a função de verossimilhança de Y condicionada a β foi possível construir a função que retornava o log da posterior.


(Q3) Após construir o algoritmo de Metropolis-Hastings foram realizadas 100.000 interações, e o resultado que deveria chegar próximo do valor do $\beta = [3, -2]$ conseguiu atingir a região mais importante, como pode ser observado nos gráficos abaixo:



(Demais) Utilizando uma variável no auxiliar no Gibbs sampler os resultados obtidos são os que se seguem nos gráficos abaixo:



Para a comparação entre os dois métodos podemos observar a evolução da cadeia de Markov da simulação e depois verificar as autocorrelações, cujos resultados estão disponíveis abaixo:



E como podemos verificar o Metropolis-Hastings de fato ficou menos autocorrelacionado. Logo o Metropolis-Hasting performou melhor.